DATA SCIENCE BIG DATA

BUSINESS ANALYTICS

INTERACT 2 HACK

BENCHMARK 360

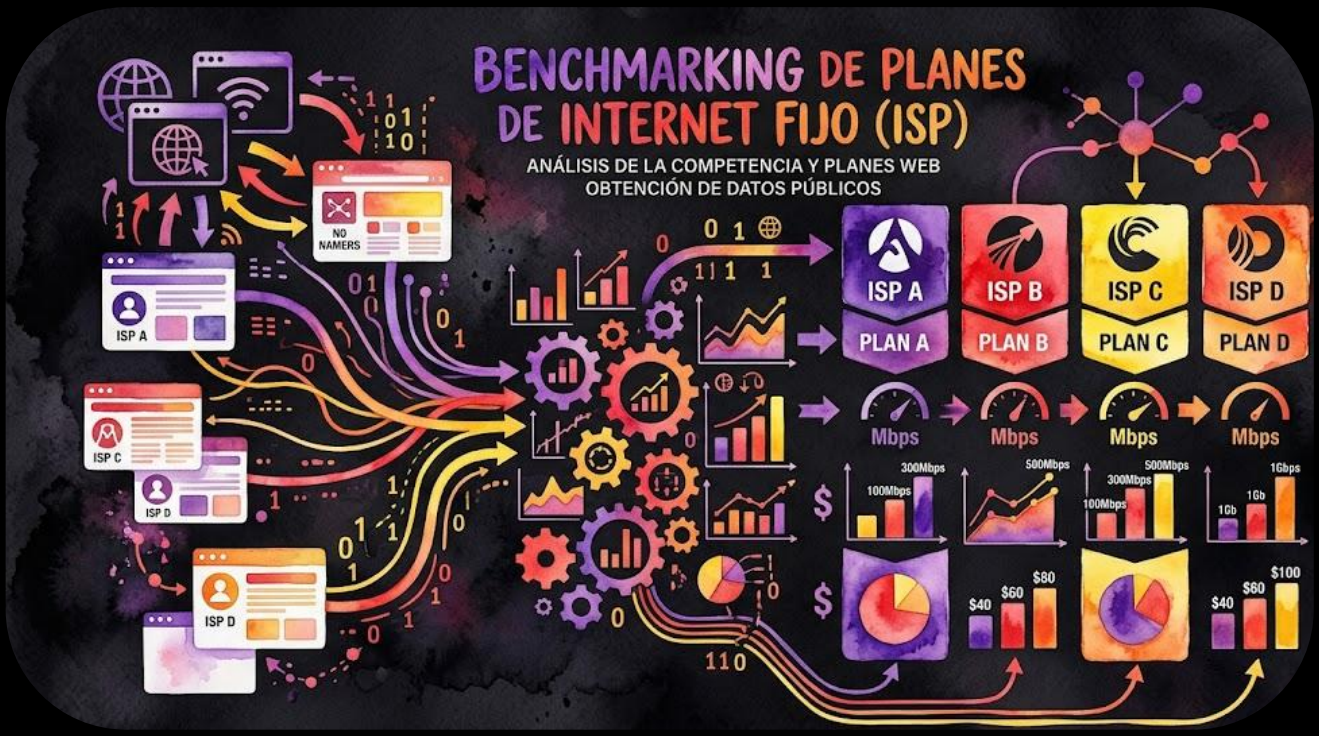

Abril 2026

Netlife ecuanet

Business Case

1 Nombre del reto

Benchmark 360: Automatización de Inteligencia Competitiva para el Mercado de Internet Fijo.

2 Línea del reto

Datos / IA aplicada a datos (Web Scraping + LLMs).

3 Problema de negocio

Actualmente, el mercado de ISPs en Ecuador es un **"océano rojo"** con más de 1400 competidores. Megadatos enfrenta una fricción crítica: la detección de cambios en los planes de la competencia (precios, bonos de velocidad, servicios de streaming incluidos) es **manual, lenta y propensa a errores**. Esta asimetría de información impide que Netlife reaccione con agilidad comercial, perdiendo ventanas de oportunidad para ajustar su oferta frente a movimientos agresivos de competidores como Claro o Xtrim.

4 Usuario, área o segmento objetivo

Usuarios: Product Managers y Analistas de Pricing.

Áreas: Gerencia de Marketing y Equipo de Estrategia de Producto.

5 Contexto y oportunidad

Hoy en día, la información comercial está dispersa en formatos no estructurados (banners, imágenes y tablas HTML dinámicas). Existe la oportunidad de crear un **Data Product** que actúe como un "sensor diario". Al automatizar la extracción y normalización de estos datos, Netlife podrá reducir el tiempo de respuesta estratégica de semanas a **menos de 24 horas**, optimizando la toma de decisiones sobre el lanzamiento de nuevos planes y servicios digitales.

6 Objetivo principal

Desarrollar un pipeline automatizado de extracción y estructuración de datos que entregue diariamente el 100% de la oferta comercial vigente de los principales ISPs competidores en un formato analítico listo para consumo.

7 Objetivos secundarios

- Implementar una arquitectura de extracción híbrida (HTML + Visión por LLM para imágenes).
- Asegurar la trazabilidad histórica de los cambios de precios y beneficios.

8 Pregunta del reto

¿Cómo podría **Netlife** automatizar el monitoreo diario de la oferta comercial de sus competidores para el **equipo de Producto**, considerando la alta volatilidad de planes y la complejidad de datos en imágenes, asegurando una estructura de datos lista para el análisis de mercado?

9 Restricciones

9.1 Tiempo:

El desarrollo debe completarse en un sprint de 32 horas.

9.2 Costo:

Prohibido el uso de APIs de pago (excepto para los modelos LLM) y herramientas libres.

9.3 Técnica:

Los scripts deben ser compatibles con **Python 3.12** y gestionar dependencias exclusivamente con **uv**.

9.4 Acceso:

No se permite el uso de técnicas de scraping que violen los términos de servicio (respetar robots.txt y usar delays razonables).

10 Data o insumos disponibles

10.1 Fuentes objetivo:

URLs oficiales de ISPs:

- Megadatos:
  - Netlife: Netlife - Internet inteligente para un mundo inteligente
  - Ecuanet: Ecuanet | Internet fibra óptica en Ecuador | Planes para hogar
- Claro: Claro - Personas | Claro: Teléfono celular y fijo, Internet, Televisión HD
- CNT: Corporación Nacional de Telecomunicaciones - CNT
- Xtrim: Planes de internet hogar en Ecuador | Desde $15,52 | Xtrim
- Puntonet: Internet para todo el Ecuador - Celerity
- Alfanet: Fibra óptica de alta velocidad en Ecuador | Alfanet
- Fibramax: Fibramax Oficial Internet de menor latencia - Disfruta de la menor latencia del mercado 700 MEGAS por solo $17.50 + imp. mensuales. juega, trabaja y disfruta sin interrupciones.

Adicionalmente, si se encuentran otras URLs, usarlas sin problemas.

10.2 Diccionario de Datos:

Esquema obligatorio de 30+ columnas (definido en la sección de entregables).

10.3 Reglas de Negocio:

Lógica para el cálculo de descuentos y manejo de planes "Arma tu plan".

11 ¿Qué deben construir, demostrar o validar los equipos?

Los equipos deben construir un **Data Pipeline "Enterprise Grade"** que realice el scraping, procese el contenido (texto e imagen) mediante LLMs para extraer variables específicas y almacene el resultado en un archivo Parquet particionado. Deben validar que la lógica de "snake_case" para servicios adicionales sea consistente.

12 Entregables esperados

12.1 Pitch del Desarrollo:

Presentación de la solución.

12.2 Archivos de Presentación:

1. Pitch del Desarrollo.

2. Archivo .pptx del slidedeck

3. Archivo .pdf del slidedeck

4. Archivo .ipynb (notebook) llamado "benchmark_industria_notebook" con código y markdowns explicatorios.

5. Archivo parquet llamado "benchmark_industria" tabla en formato parque con las siguientes columnas:

- fecha: fecha de extracción de datos. formato datetime con fecha y hora exacta hasta el segundo.

- anio: año de la fecha

- mes: mes de la fecha

- dia: dia de la fecha.

- empresa: empresa de internet. Nombre con el que está registrado en la Superintendencia de Compañias.

- marca: marca del servicio de la empresa de internet. Una empresa puede tener varias marcas.

- nombre_plan: nombre del plan de internet.

- velocidad_download_mbps: velocidad de descarga en la unidad mbps.

- velocidad_upload_mbps: velocidad de subida en la unidad mbps.

- precio_plan: valor real en dólares del plan (sin IVA), sin descuentos mensuales(precio principal).

- precio_plan_tarjeta: valor en dólares del plan (sin IVA), sin descuentos mensuales, si se paga con tarjeta de crédito.

- precio_plan_debito: valor en dólares del plan (sin IVA), sin descuentos mensuales, si se paga con tarjeta de debido o cuenta de ahorros o cuenta corriente.

- precio_plan_efectivo: valor en dólares del plan (sin IVA), sin descuentos mensuales, si se paga con efectivo.

- precio_plan_descuento: valor en dólares del plan (sin IVA), con descuentos mensuales.

- descuento: porcentaje de descuento en la mensualidad del plan, calculado con la fórmula: ((precio_plan-precio_plan_descuento)/precio_plan).

-meses_descuento: cantidad de meses donde se aplica el decuento en la mensualidad.

- costo_instalacion: valor en dólares del costo total de instalación (con IVA).

- comparticion: compartición del servicio de internet.

- pys_adicionales: cantidad productos y servicios adicionales con el plan.

- pys_adicionales_detalle: diccionario de donde los "keys" son nombres productos y servicios adicionales con el plan. Estos nombres deberán estar estandarizados "snake_case" en toda la tabla.

Ejemplo:

"Disney Plus" y "disney +" deberán ser un solo valor "disney_plus". Los "values" del diccionario principal será otro diccionario que contenga como "keys": "tipo_plan" el nombre exacto del plan de la plataforma, "meses" la cantidad de meses que se da el beneficio y "categoría" que es la categoría del tipo de producto o servicio.

Ejemplo:

```
{
  "disney_plus": {
    "tipo_plan": "disney_plus_premium", # también podría ser "disney_plus_basic"
    "meses": 9,
    "categoria": "streaming"
  },
  "netlife_defense": {
    "tipo_plan": "kaspersky_basic",
    "meses": 36, # dura el tiempo total del contrato
    "categoria": "streaming" # las categorías las inventan ustedes
  },
  ...
}
```

- meses_contrato: cantidad mínima de meses por los que se hace el contrato.

- facturas_gratis: cantidad de facturas que no debe pagar el cliente.

- tecnologia: tipo de tecnología usada. Ejemplo: "fibra_optica", "fttp", "cobre", etc.

- sectores: lista de sectores geográficos que tienen algún tipo de beneficio extra.

- parroquia: lista de parroquias que tienen algún tipo de beneficio extra.

- cantón: lista de cantones que tienen algún tipo de beneficio extra.

- provincia: lista de provincias que tienen algún tipo de beneficio extra.

- factura_anterior: booleano que indica si se debe presentar la factura del ISP actual.

- terminos_condiciones: str de terminos y condiciones del plan.

- beneficios_publicitados: str de características publicitadas del plan. Ejemplo: "alta velocidad".

13 Formato de entrega final del equipo

Pitch + Presentación + Notebook Funcional + Archivo Parquet de muestra con al menos 20 registros extraídos.

14 Criterios de éxito para Netlife

14.1 Precisión:

>95% de coincidencia entre los datos extraídos por el bot y la realidad de la página web.

14.2 Estandarización:

Correcta aplicación del diccionario de pys_adicionales en formato JSON/Dictionary.

14.3 Robustez:

Manejo exitoso de planes tipo "Arma tu plan" mediante la generación de registros por cada combinación posible.

15 ¿Qué evaluará el jurado?

15.1 Relevancia para el negocio:

¿La herramienta permite tomar decisiones de pricing inmediatas?

15.2 Calidad analítica:

Uso correcto de Pydantic V2 para validación de esquemas.

15.3 Viabilidad técnica:

Eficiencia en el uso de memoria y velocidad de ejecución con uv.

15.4 Seguridad:

Implementación de guardrails contra *Prompt Injection* en los prompts del LLM.

15.5 Clean Code:

Cumplimiento estricto de PEP8 y documentación Google Style.

16 Supuestos

Se asume que los sitios web de los ISPs son accesibles mediante peticiones estándar durante las 32 horas del evento.

La información de la Superintendencia de Compañías se utilizará para el mapeo estático de los nombres legales de las empresas.